Rapport de Travaux Pratiques N°3

Analyse de Sentiments sur le Dataset IMDB

Classification binaire d'avis cinématographiques par apprentissage automatique

Étudiant : Ayman Joundi
Formation : Master AIDC
Université : FST BENI MELLAL

17 octobre 2026

Résumé

Ce rapport présente la mise en œuvre d'un système de classification automatique d'avis cinématographiques (analyse de sentiments) sur le dataset public *IMDB Dataset of 50K Movie Reviews*. L'objectif est de prédire si un avis est positif ou négatif à partir de son contenu textuel. Nous détaillons l'ensemble de la chaîne de traitement : exploration des données, prétraitement du texte (nettoyage, lemmatisation, suppression des *stopwords*), extraction de caractéristiques par TF-IDF (5 000 mots), puis entraînement et évaluation de deux classifieurs. Les résultats obtenus atteignent une précision (Accuracy) de **88,48 %** pour la Régression Logistique et **84,90 %** pour Naïve Bayes Multinomial, confirmant la pertinence des approches linéaires pour cette tâche. Une discussion sur les limites et les perspectives (modèles à base de Transformers) conclut ce travail.

Mots-clés : Analyse de sentiments, NLP, TF-IDF, Régression Logistique, Naïve Bayes, IMDB.

Table des matières

1 Introduction **4**
1.1 Contexte 4
1.2 Objectif du TP 4

2 Présentation du dataset **4**
2.1 Description et Statistiques 4

3 Méthodologie **4**
3.1 Chaîne de traitement 4
3.2 Vectorisation TF-IDF 5

4 Résultats expérimentaux **5**
4.1 Performances globales 5
4.2 Évaluation détaillée (Régression Logistique) 6
4.3 Tests de prédiction sur des avis inédits 7

5 Discussion et perspectives **7**
5.1 Interprétation 7
5.2 Limites 7
5.3 Perspectives 7

6 Conclusion **8**

A Annexe A – Code source **8**

1 Introduction

1.1 Contexte

L'analyse de sentiments (*sentiment analysis*) est une tâche fondamentale du traitement automatique du langage naturel (NLP). Elle consiste à déterminer automatiquement la polarité d'un texte (positive, négative ou neutre). Ses applications sont nombreuses : veille d'opinion, analyse de retours clients, modération de contenus, etc.

1.2 Objectif du TP

Ce travail pratique vise à concevoir un classifieur binaire capable de prédire le sentiment d'un avis cinématographique. Le dataset utilisé est le *IMDB Dataset of 50K Movie Reviews*, composé de 50 000 avis étiquetés manuellement comme positifs ou négatifs.

2 Présentation du dataset

2.1 Description et Statistiques

Le dataset contient deux colonnes : `review` (le texte brut de l'avis) et `sentiment` (l'étiquette : `positive` ou `negative`). Le tableau 1 résume les caractéristiques principales.

Table 1 – Statistiques descriptives du dataset IMDB.

Caractéristique	**Valeur**
Nombre total d'avis	50 000
Nombre d'avis positifs	25 000
Nombre d'avis négatifs	25 000
Longueur moyenne d'un avis	$\approx$ 230 mots
Classes	2 (équilibrées)

L'équilibre parfait entre les deux classes (50/50) évite tout biais de classe lors de l'apprentissage et permet d'utiliser l'*accuracy* comme métrique principale fiable.

3 Méthodologie

3.1 Chaîne de traitement

La chaîne de traitement adoptée est la suivante :

1. Chargement et exploration des données ;
2. Prétraitement du texte (suppression des balises HTML, ponctuation, *stopwords*, lemmatisation) ;
3. Vectorisation TF-IDF limitée à 5 000 caractéristiques ;
4. Séparation entraînement/test (80 %/20 %) ;

5. Entraînement de deux classifieurs (Régression Logistique et Naïve Bayes Multinomial) ;
6. Évaluation par accuracy, matrice de confusion et tests sur des avis inédits.

3.2 Vectorisation TF-IDF

Le texte nettoyé est transformé en une matrice TF-IDF (*Term Frequency – Inverse Document Frequency*). Comme le montre l'exécution du TP, la matrice générée a bien les dimensions suivantes : **(50000, 5000)**, soit 50 000 documents décrits par 5 000 mots.

4 Résultats expérimentaux

4.1 Performances globales

Le tableau 2 présente les performances des deux modèles sur l'ensemble de test (10 000 avis).

Modèle	**Accuracy**	**Commentaire**
Régression Logistique	**0,8848** (88,48 %)	Meilleur modèle global
Naïve Bayes Multinomial	0,8490 (84,90 %)	Légèrement moins précis

TABLE 2 – Comparaison des performances des deux classifieurs.

4.2 Évaluation détaillée (Régression Logistique)

Le rapport de classification et la matrice de confusion de la Régression Logistique sont présentés ci-dessous. Le modèle obtient une excellente précision et un rappel équilibré (environ 0.88 pour les deux classes).

```
--- Évaluation du modèle ---
Accuracy : 0.8848

Rapport de classification :
              precision    recall  f1-score   support

    negative       0.89      0.87      0.88      4961
    positive       0.88      0.90      0.89      5039

    accuracy                           0.88     10000
   macro avg       0.89      0.88      0.88     10000
weighted avg       0.89      0.88      0.88     10000
```

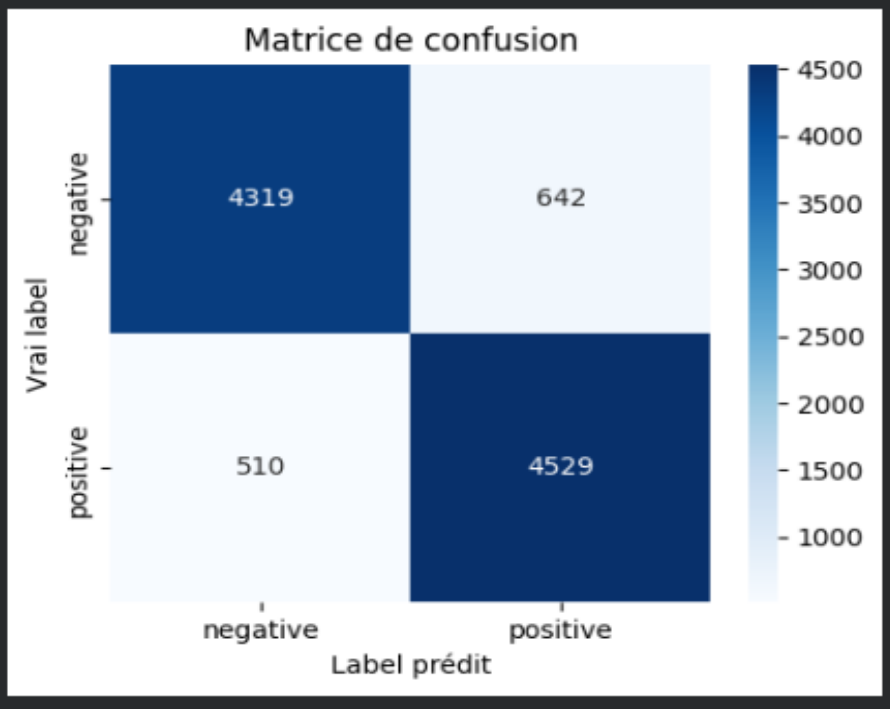


FIGURE 1 – Rapport de classification (haut) et Matrice de confusion (bas) pour la Régression Logistique.

4.3 Tests de prédiction sur des avis inédits

Afin de valider la robustesse du modèle, quatre avis ont été soumis au système. Les résultats (Figure 2) montrent que le modèle identifie correctement les sentiments forts. On notera que l'avis neutre (*« It was okay, not great but not bad either »*) est classé comme négatif, ce qui illustre la difficulté de traiter la neutralité dans un modèle binaire.

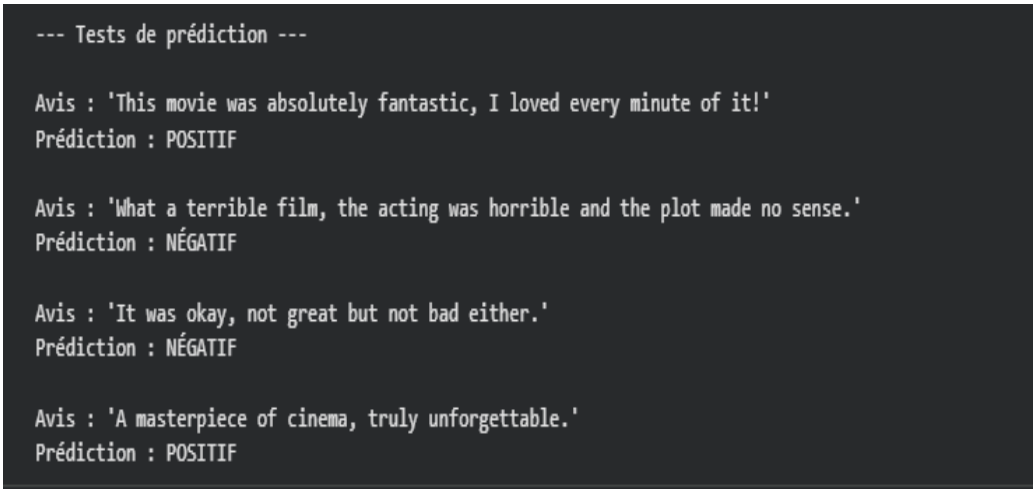


FIGURE 2 – Prédictions du modèle sur quatre avis inédits.

5 Discussion et perspectives

5.1 Interprétation

Les résultats confirment que la représentation TF-IDF capture efficacement l'information discriminante. La Régression Logistique surpasse Naïve Bayes (88,48 % contre 84,90 %) car elle gère mieux les dépendances entre les mots, tandis que Naïve Bayes suppose une indépendance stricte des caractéristiques.

5.2 Limites

— **Perte du contexte** : TF-IDF ignore l'ordre des mots, rendant difficile la gestion des négations complexes.
— **Gestion de la neutralité** : Le modèle binaire force la classification des avis mitigés (comme l'avis n°3) dans l'une des deux extrêmes.

5.3 Perspectives

L'utilisation de modèles pré-entraînés de type **BERT** ou **RoBERTa** permettrait de capturer le contexte sémantique et d'améliorer la gestion des phrases neutres ou ironiques.

6 Conclusion

Ce TP a permis de mettre en œuvre une chaîne complète d'analyse de sentiments. Les modèles classiques (TF-IDF + Régression Logistique) atteignent une précision très satisfaisante de près de 88,5 %, validant l'approche pour un déploiement de base. L'expérimentation a également mis en évidence l'importance cruciale du prétraitement des données textuelles.

A Annexe A – Code source

Listing 1 – Prétraitement et vectorisation TF-IDF.

```
from sklearn.feature_extraction.text import TfidfVectorizer

# Initialiser le vectorizer
# max_features=5000 limite le vocabulaire aux 5000 mots les plus fr quents
vectorizer = TfidfVectorizer(max_features=5000)

# Transformer le texte nettoye en matrice TF-IDF
X = vectorizer.fit_transform(df['cleaned_review'])

# Transformer les labels (positive/negative) en 1/0
y = df['sentiment'].map({'positive': 1, 'negative': 0})

print(X.shape) # Affiche (50000, 5000)
```

Listing 2 – Entraînement des modèles.

```
from sklearn.linear_model import LogisticRegression
from sklearn.naive_bayes import MultinomialNB
from sklearn.metrics import accuracy_score

# Regression Logistique
model = LogisticRegression(max_iter=1000)
model.fit(X_train, y_train)
y_pred = model.predict(X_test)
print(f"Accuracy : {accuracy_score(y_test, y_pred):.4f}") # 0.8848

# Naive Bayes
nb_model = MultinomialNB()
nb_model.fit(X_train, y_train)
y_pred_nb = nb_model.predict(X_test)
print(f"Accuracy : {accuracy_score(y_test, y_pred_nb):.4f}") # 0.8490
```